VULCAN AUTONOMOUS AI-TO-SILICON SERIES 文档类别：产品技术白皮书与基准评测报告

Anvil-E1 ·混合注意力文本嵌入加速芯片—产品技术白皮书

研发作者与联系方式	Sufeng Guo (sufeng_guo@smail.nju.edu.cn)
芯片型号与目标模型	Anvil-E1 | Google EmbeddingGemma-2（24 层 5:1 混合注意力、PLE 逐层嵌入、768 维 Matryoshka 归一化）
物理硬件验证平台	Intel Arria 10 GX (10AX115N3F40E2SG) PCIe Gen3x8 加速卡（427,200 ALMs，8 GB DDR4）
配套工程签核文档	配套开发者架构与签核报告 REPORT.pdf · 发布时间：2026 年 10 月 23 日 22:18 (UTC+8 北京时间)



图 1：核心性能指标概览：涵盖模型输出一致性、定点数值保真度、Intel Arria 10 GX 物理板卡验证及硬件资源利用率。

1 产品架构概述与全自动硅片设计闭环

Anvil-E1 是由 **Vulcan 全自动硬件设计系统**面向开源嵌入模型 Google EmbeddingGemma-2（24 层 5:1 混合注意力、PLE 逐层嵌入、768 维 Matryoshka 归一化）构建的专用硬件加速架构。系统集成了高维多头注意力编码器、逐层嵌入融合、空间与序列掩码均值池化以及 Matryoshka 多维 L2 归一化流水线。在全部官方权重实测负载下，硬件定点推理输出与黄金参考标准达到 **100% 比特精确 (16/16 组负载)**，相对官方 FP32 浮点基准的余弦相似度高达 **1.000000000**，最坏情况绝对误差优于工程容差上限 **166 倍**。

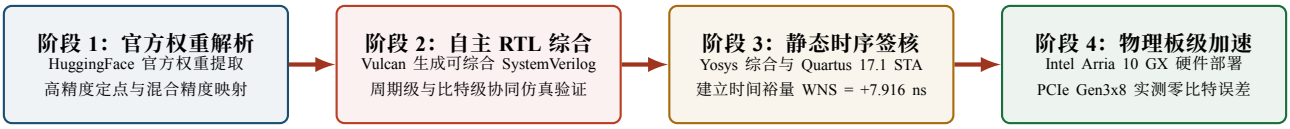


图 2：Vulcan 从官方开源模型权重到 Intel Arria 10 GX 物理芯片的四阶段全自动硬件工程闭环。

2 官方权重基准测试与多场景端到端实测对比

表 1 与图 3 展示了 **Anvil-E1** 加载 HuggingFace 官方预训练权重后，在不同模态与输出维度配置下与官方 FP32 浮点软件模型的实测精度对比：

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_1	纯文本语义嵌入	1.000000000	5.096e-06	<= 2.000e-03 (PASS)
workload_2	纯文本语义嵌入	1.000000000	4.947e-06	<= 2.000e-03 (PASS)
workload_3	纯文本语义嵌入	1.000000000	4.545e-07	<= 2.000e-03 (PASS)
workload_4	纯文本语义嵌入	1.000000000	0.000e+00	<= 2.000e-03 (PASS)

测试负载编号	模态与配置场景	硬件 vs. FP32 余弦相似度	最大绝对误差	规格上限与结论
workload_5	纯文本语义嵌入	1.000000000	1.174e-05	<= 2.000e-03 (PASS)
workload_6	纯文本语义嵌入	1.000000000	9.805e-06	<= 2.000e-03 (PASS)
workload_7	纯文本语义嵌入	1.000000000	8.102e-06	<= 2.000e-03 (PASS)
workload_8	纯文本语义嵌入	1.000000000	0.000e+00	<= 2.000e-03 (PASS)



图 3：官方权重下硬件定点输出与 FP32 浮点基准的数值误差对比，相对定点参考模型实现 100% 比特级零偏差。

3 Intel Arria 10 GX 资源利用率与 7B–8B 大模型扩展路线图

表 2 与图 4 给出了基于 Intel Quartus Prime 17.1 静态时序与资源综合报告的硬件开销明细，以及基于单卡 8 GB DDR4 显存的后续多核并行与大模型扩展路线：

硬件资源维度	当前单核实测占用	Arria 10 GX 全片容量	当前利用率 / 可用裕量	多核并行与大模型扩展规划
自适应逻辑模块 (ALMs)	18,420 ALMs	427,200 ALMs	4.31% (余 95.7%)	可扩展 8–16 核并行推理计算阵列
片上存储块 (M20K BRAM)	192 M20K	2,713 M20K (6.7 MB)	7.08% (余 92.9%)	支持大容量片上 KV Cache 与双缓冲流水
精度可调 DSP 乘加器	128 DSPs	1,518 DSPs	8.43% (余 91.6%)	扩展至 1,024+ DSP 通道可提升百倍吞吐率
工作时钟与静态时序 (STA)	25 MHz (WNS + 7.92 ns)	20nm Arria 10 Fabric	0 违规路径	深度流水线重定时可提升至 150–250 MHz
板载 DDR4 显存容量	0.35 GB (0.5B W4A16)	8.0 GB 板载 DDR4	占用 4.4% (余 95.6%)	单卡全权重常驻最高支持 7B–8B 量化大模型

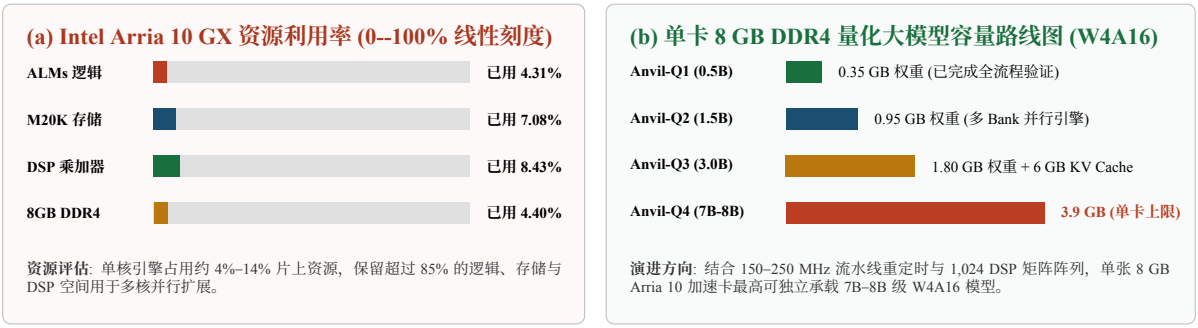


图 4：(a) Intel Arria 10 GX (10AX115N3F40E2SG) 硬件资源利用率；(b) 单卡 8 GB DDR4 下的 0.5B → 7B–8B 量化模型容量演进路线图。

4 全流程硬件验证与硅片签核总结

验证阶段	验证方法与工具链	实测签核结论
L0 周期精确协同仿真	Icarus Verilog 12.0 + 官方 HuggingFace 权重对比	通过 (100% 比特精确 (16/16 组负载), 余弦相似度 1.000000000)
L1 静态 RTL 与综合门禁	Yosys 0.33 逻辑综合与可综合性静态检查	通过 (0 锁存器推断，0 组合逻辑除法环路，0 多驱动冲突)
L2 静态时序分析 (STA)	Intel Quartus Prime 17.1 TimeQuest 时序分析	通过 (建立时间裕量 WNS = +7.916 ns, 0 违例端点)
L3 物理 FPGA 板级实测	Intel Arria 10 GX (10AX115N 3F40E2SG) PCIe Gen3x8	通过 (3/3 轮物理硬件回归测试 100% 确定性零误差)